



PUC
CAMPINAS
PONTIFÍCIA UNIVERSIDADE CATÓLICA

Tópicos Avançados de Redes para Datacenter

Antonio Forster

antonio.forster@puc-campinas.edu.br

Escola Politécnica - Setembro/2026


Pontifícia Universidade Católica de Campinas

Tópicos avançados de redes para Datacenter

- Border Gateway Protocol — BGP
- Virtual Extensible LAN — VXLAN
- Ethernet VPN — EVPN


Uso dessas tecnologias em redes modernas de Data Centers e Cloud

Da Fabric para BGP e VXLAN




- Uma Network Fabric, normalmente baseada em arquitetura Leaf-Spine, fornece múltiplos caminhos entre os dispositivos de um Data Center.
- Essa infraestrutura pode utilizar roteamento IP e mecanismos como ECMP para distribuir o tráfego entre caminhos de mesmo custo.
- Sobre essa rede física podemos construir uma rede lógica ou overlay, independente da topologia física utilizada pelo Data Center.
- Uma implementação muito comum atualmente utiliza VXLAN como tecnologia de overlay e BGP EVPN como mecanismo de controle dessa rede virtual.

O que é BGP?




- BGP — Border Gateway Protocol é um protocolo de roteamento utilizado para trocar informações de alcançabilidade entre diferentes redes IP.
- Diferentemente de protocolos como OSPF, o BGP não procura apenas o caminho de menor custo; ele utiliza políticas e atributos para decidir qual caminho utilizar.
- O BGP foi desenvolvido principalmente para permitir a interconexão entre grandes redes independentes, sendo o protocolo responsável pelo roteamento entre sistemas autônomos na Internet.
- Atualmente o BGP também é amplamente utilizado em outros ambientes, como grandes backbones MPLS e dentro de Data Centers, inclusive como parte de arquiteturas Leaf-Spine e VXLAN/EVPN.

Autonomous System — AS




- Um Autonomous System — AS representa um conjunto de redes administradas sob uma política de roteamento comum.
- Cada Autonomous System utilizado na Internet possui um identificador denominado ASN — Autonomous System Number.
- Operadoras, grandes empresas, provedores de Cloud e outras organizações podem possuir seus próprios Autonomous Systems.
- O BGP permite que esses sistemas troquem informações sobre quais redes podem ser alcançadas através de cada AS.

eBGP e iBGP



- Quando uma sessão BGP é estabelecida entre roteadores pertencentes a Autonomous Systems diferentes, ela é denominada eBGP — External BGP.
- Quando os roteadores pertencem ao mesmo Autonomous System, a sessão é denominada iBGP — Internal BGP.
- Na Internet, o eBGP é utilizado principalmente para troca de rotas entre organizações ou provedores diferentes.
- Em redes corporativas e Data Centers, tanto eBGP quanto iBGP podem ser utilizados, dependendo da arquitetura escolhida.

Como uma sessão BGP funciona?




- Antes de trocar rotas, dois roteadores BGP estabelecem uma sessão TCP, utilizando normalmente a porta TCP 179.
- Depois que a sessão é estabelecida, os equipamentos passam a trocar informações sobre redes que conseguem alcançar.
- O BGP mantém essas informações e seleciona os melhores caminhos de acordo com seus atributos e políticas configuradas.
- Alterações na topologia normalmente geram a propagação apenas das mudanças necessárias, e não o envio periódico de toda a tabela.

iBGP, Full Mesh e Route Reflector

- Em uma rede utilizando iBGP, os roteadores BGP de um mesmo Autonomous System precisam trocar entre si as informações de roteamento aprendidas.
- Em uma arquitetura iBGP tradicional, isso leva à necessidade de estabelecer uma Full Mesh de sessões iBGP, ou seja, cada roteador iBGP mantém uma sessão direta com todos os demais.
- À medida que aumenta a quantidade de roteadores, cresce também o número de sessões BGP necessárias, tornando a arquitetura mais complexa de operar.
- Um Route Reflector — RR permite reduzir essa necessidade de Full Mesh: determinados roteadores estabelecem sessões com o Route Reflector, que passa a refletir os anúncios BGP entre seus clientes.

BGP Route Reflector




O que o BGP anuncia?



- No funcionamento tradicional do BGP, os roteadores anunciam prefixos IP, informando que determinada rede pode ser alcançada através deles.
- Um anúncio contém a informação da rede alcançável e diversos atributos associados ao caminho utilizado para alcançá-la.
- Exemplo: um roteador pode informar a outro que a rede 200.10.20.0/24 é alcançável através do seu Autonomous System.
- Esses anúncios formam a base para que cada roteador construa sua visão dos possíveis caminhos existentes.

BGP é um protocolo de Path Vector




- O BGP é normalmente classificado como um protocolo de Path Vector, pois seus anúncios carregam informações sobre o caminho percorrido até determinado destino.
- Um dos principais atributos utilizados para isso é o AS_PATH, que contém a sequência de Autonomous Systems atravessados pelo anúncio.
- Esse mecanismo permite ao BGP conhecer não apenas a existência de um destino, mas também parte do caminho utilizado para chegar até ele.
- O AS_PATH também ajuda a evitar loops: um AS rejeita normalmente uma rota se encontrar seu próprio número dentro do caminho anunciado.

Principais atributos do BGP

- AS_PATH: apresenta os Autonomous Systems atravessados pelo anúncio e participa da seleção do melhor caminho.
- NEXT_HOP: identifica o endereço IP do próximo roteador que deve ser utilizado para alcançar o destino anunciado.
- LOCAL_PREF: permite estabelecer preferências de saída dentro de um Autonomous System.
- Outros atributos, como MED, Communities e Weight, permitem implementar políticas de roteamento mais sofisticadas.

Seleção de caminhos no BGP




- Um roteador BGP pode receber mais de um anúncio para o mesmo prefixo, proveniente de diferentes vizinhos ou caminhos.
- O BGP compara os atributos dessas rotas para determinar qual delas será considerada o melhor caminho.
- Entre os critérios podem aparecer preferências administrativas, LOCAL_PREF, tamanho do AS_PATH, origem da rota, MED e características do próximo salto.
- Portanto, diferentemente de um protocolo puramente baseado em menor métrica, o BGP foi projetado para permitir controle por políticas.

BGP versus OSPF

Característica	OSPF	BGP
Escopo	Intra-domínio	Inter-domínios
Critério	Menor custo	Políticas e atributos
Uso típico	Redes internas	Internet / DC
Tipo	Link State	Path Vector

- OSPF é um protocolo IGP desenvolvido principalmente para calcular caminhos dentro de uma rede administrada de forma relativamente integrada.
- BGP foi desenvolvido para trocar informações de alcançabilidade entre domínios e permitir a aplicação de políticas de roteamento.
- No OSPF, o critério fundamental é encontrar o caminho de menor custo; no BGP, diversos atributos e políticas participam da decisão.
- Em grandes redes, é possível inclusive utilizar OSPF em determinadas funções internas e BGP em outros níveis da arquitetura.

BGP em Data Centers




- Embora tenha surgido principalmente como protocolo de roteamento entre Autonomous Systems da Internet, o BGP passou a ser amplamente utilizado também em grandes Data Centers.
- Arquiteturas Leaf-Spine combinam naturalmente com roteamento IP, pois existem vários caminhos paralelos entre os switches Leaf através dos switches Spine.
- Uma forma de implementação muito comum utiliza eBGP entre switches Leaf e Spine, atribuindo diferentes Autonomous Systems aos equipamentos.
- O roteamento IP da Fabric fornece então a conectividade básica utilizada posteriormente pelo VXLAN.

Por que se faz isso? (Vantagens do eBGP)

- Em vez de usar protocolos tradicionais (como OSPF ou iBGP), a indústria adotou o eBGP (Sistemas Autônomos diferentes entre vizinhos) na malha física (Underlay) por três razões principais:
 - Fim dos Route Reflectors: O iBGP exige uma malha completa de conexões ou servidores de rotas (Route Reflectors). O eBGP elimina essa complexidade.
 - Prevenção de Loops Nativa: O BGP rejeita automaticamente rotas que contenham o seu próprio ASN no caminho. Isso evita loops na malha de forma extremamente eficiente.
 - Escalabilidade: É o protocolo que move a internet; ele lida com milhares de rotas e mudanças de topologia sem sofrer com gargalos de processamento.

Underlay e Overlay




- Em arquiteturas modernas de Data Center é importante separar os conceitos de Underlay e Overlay.
- O Underlay é a infraestrutura IP física que fornece conectividade entre os switches e permite que qualquer equipamento da Fabric alcance os demais.
- O Overlay cria redes lógicas sobre essa infraestrutura, sem exigir que a topologia lógica tenha a mesma estrutura da topologia física.
- O VXLAN é uma das tecnologias utilizadas para construir esse Overlay.

Limitações das VLANs tradicionais


- VLANs permitem criar diferentes domínios de camada 2 sobre uma mesma infraestrutura física, mas possuem limitações quando utilizadas em Data Centers muito grandes.
- O identificador de VLAN possui 12 bits, permitindo aproximadamente 4.000 VLANs utilizáveis, o que pode ser insuficiente em ambientes de grande escala e multi-tenant.
- Além disso, estender grandes domínios Layer 2 pela infraestrutura pode ampliar domínios de broadcast e dificultar a escalabilidade.
- Data Centers modernos procuram manter o núcleo da rede predominantemente Layer 3, construindo as redes Layer 2 virtualizadas sobre essa infraestrutura.

O que é VXLAN?

- VXLAN — Virtual Extensible LAN é uma tecnologia que permite transportar quadros Ethernet através de uma rede IP.
- O quadro Ethernet original é encapsulado dentro de um pacote UDP/IP, permitindo atravessar uma infraestrutura Layer 3.
- Dessa forma, dois equipamentos conectados a diferentes partes da Fabric podem participar da mesma rede lógica Layer 2.
- O VXLAN cria, portanto, uma rede Overlay Layer 2 sobre uma rede Underlay Layer 3.




Maior escala e multi-tenant com VXLAN



Encapsulamento VXLAN

- Quando um quadro Ethernet precisa atravessar a Fabric, o equipamento de entrada adiciona um cabeçalho VXLAN, seguido de UDP e IP.
- A rede física transporta o pacote utilizando apenas os endereços IP externos, sem precisar conhecer diretamente os endereços MAC existentes dentro do VXLAN.
- Ao chegar ao equipamento de destino, os cabeçalhos externos são removidos e o quadro Ethernet original é novamente encaminhado.
- A porta UDP utilizada pelo VXLAN é normalmente 4789.




VNI — VXLAN Network Identifier

VLAN	VNI
10	10010
20	10020
30	10030
40	10040
...	...

VNI: 24 bits (~ 16 milhões)


- Cada rede lógica VXLAN é identificada através de um VNI — VXLAN Network Identifier.
- O VNI possui 24 bits, permitindo aproximadamente 16 milhões de identificadores, muito mais do que os aproximadamente 4 mil identificadores disponíveis em VLANs.
- Diferentes VNIs representam redes virtuais logicamente independentes utilizando a mesma infraestrutura IP física.
- Uma VLAN presente na borda da rede pode ser associada a determinado VNI para ser transportada através da Fabric.

VTEP — VXLAN Tunnel Endpoint



- O equipamento responsável por encapsular e desencapsular os pacotes VXLAN é denominado VTEP — VXLAN Tunnel Endpoint.
- Em Data Centers, a função de VTEP normalmente é executada pelos switches Leaf, embora também possa existir em dispositivos virtuais ou hypervisors.
- Cada VTEP possui um endereço IP na rede Underlay, utilizado como origem ou destino dos pacotes VXLAN.
- Para o Underlay, portanto, a comunicação VXLAN aparece simplesmente como tráfego IP entre VTEPs.

Comunicação através de VXLAN



- Quando o servidor A envia um quadro para um servidor conectado a outro Leaf, o VTEP de entrada identifica o VNI correspondente àquela rede virtual.
- O VTEP encapsula o quadro Ethernet dentro de VXLAN/UDP/IP e utiliza como endereço IP de destino o VTEP remoto.
- Os switches Spine encaminham o pacote utilizando apenas o roteamento IP da rede Underlay.
- O VTEP remoto remove o encapsulamento VXLAN e entrega o quadro Ethernet original ao servidor de destino.

O problema: como o VTEP encontra os MACs?

- O VXLAN define como encapsular e transportar o tráfego, mas ainda existe uma questão importante: como um VTEP sabe em qual VTEP remoto está determinado MAC address?
- Uma solução inicial é utilizar mecanismos de Flood and Learn, de forma semelhante ao aprendizado tradicional realizado por switches Ethernet.
- Tráfego broadcast, unknown unicast e multicast pode ser replicado através do Overlay para descobrir os destinos existentes.
- Esse modelo funciona, mas pode gerar maior volume de tráfego e não escala tão bem em Data Centers muito grandes.




VXLAN Flood and Learn




- No modelo Flood and Learn, um VTEP aprende os endereços MAC locais observando os quadros recebidos dos equipamentos conectados a ele.
- Quando o destino ainda não é conhecido, o tráfego pode precisar ser enviado a vários VTEPs participantes daquele VNI.
- Os VTEPs remotos aprendem a localização dos MAC addresses a partir dos quadros VXLAN recebidos.
- Em ambientes grandes, essa necessidade de flooding motivou a adoção de um Control Plane capaz de distribuir as informações de MAC de forma mais eficiente.

De Flood and Learn para um Control Plane




- Em vez de depender exclusivamente da observação do tráfego para descobrir onde cada MAC address está localizado, podemos distribuir essa informação através de um protocolo de controle.
- Cada VTEP informa aos demais quais MAC addresses estão conectados localmente a ele.
- Os outros equipamentos passam a conhecer antecipadamente a localização desses dispositivos, reduzindo a necessidade de flooding.
- O protocolo amplamente utilizado para realizar essa troca de informações é o BGP utilizando EVPN.

O que é EVPN?



- EVPN — Ethernet VPN é uma tecnologia de Control Plane utilizada para distribuir informações relacionadas a redes Ethernet.
- O EVPN permite anunciar através do BGP informações como MAC addresses, endereços IP, VNIs e localização dos dispositivos na Fabric.
- Para isso é utilizada uma extensão do BGP conhecida como MP-BGP — Multiprotocol BGP, capaz de transportar diferentes famílias de informações além das rotas IPv4 tradicionais.
- Em uma arquitetura VXLAN/EVPN, portanto, VXLAN transporta os dados e EVPN distribui as informações necessárias para localizar os destinos.

O que é MP-BGP?



- MP-BGP — Multiprotocol BGP é uma extensão do BGP que permite transportar, através da mesma arquitetura de protocolo, informações de alcançabilidade diferentes das rotas IPv4 tradicionais.
- Em vez de o BGP trabalhar apenas com prefixos IPv4, o MP-BGP permite transportar informações de diferentes protocolos ou serviços, como IPv6, VPNs MPLS e EVPN.
- Cada tipo de informação é tratado dentro de uma *Address Family*, que identifica semanticamente o que está sendo anunciado.
- A sessão continua sendo BGP sobre TCP porta 179; o que muda é o tipo de informação carregada nos anúncios.

Address Families no MP-BGP

- Uma Address Family — AF identifica o tipo de endereço ou informação de alcançabilidade transportada pelo BGP.
- O MP-BGP utiliza identificadores denominados AFI — Address Family Identifier e SAFI — Subsequent Address Family Identifier para diferenciar esses tipos de informação.
- O AFI identifica de forma geral a família, como IPv4, IPv6 ou L2VPN, enquanto o SAFI especifica o tipo de serviço ou de rota dentro daquela família.
- Assim, uma mesma sessão BGP pode transportar várias famílias de informações, desde que elas sejam negociadas entre os peers.

Exemplos de Address Families

Address Family	O que transporta
IPv4 Unicast	Prefixos IPv4
IPv6 Unicast	Prefixos IPv6
VPNv4 / VPNv6	Rotas de VPNs (MPLS)
L2VPN EVPN	MAC, IP e informações do Overlay


- IPv4 Unicast: transporta os prefixos IPv4 tradicionais, como 10.10.0.0/16 ou 192.168.1.0/24.
- IPv6 Unicast: permite que o BGP transporte prefixos IPv6 utilizando o mesmo mecanismo básico de troca de rotas.
- VPNv4/VPNv6: utilizadas em redes MPLS para transportar rotas pertencentes a diferentes VPNs ou clientes.
- L2VPN EVPN: permite transportar informações relacionadas a redes Ethernet, incluindo MAC addresses, endereços IP e informações associadas ao Overlay.

MP-BGP: BGP além de rotas IPv4

- O BGP tradicionalmente é associado ao anúncio de prefixos IPv4, porém sua arquitetura foi estendida através do Multiprotocol BGP — MP-BGP.
- O MP-BGP permite transportar diferentes tipos de NLRI — Network Layer Reachability Information, organizadas em diferentes Address Families.
- Isso permite utilizar BGP para diversas aplicações, como IPv6, MPLS VPNs, multicast e EVPN, mantendo o mesmo mecanismo básico de estabelecimento de sessões e troca de atributos.
- No caso de VXLAN/EVPN, utiliza-se a família L2VPN EVPN, permitindo anunciar informações como MAC addresses, IPs e localização dos endpoints.

Anunciando um MAC através de BGP EVPN

- Imagine que uma máquina virtual com MAC AA:AA:AA:AA:AA:01 esteja conectada ao Leaf 1 e pertença ao VNI 10010.
- O Leaf 1 aprende localmente esse MAC e, através de BGP EVPN, anuncia aos outros VTEPs que esse endereço pode ser alcançado através dele.
- O Leaf 2 recebe o anúncio e associa o MAC da máquina remota ao endereço IP do VTEP do Leaf 1.
- Quando precisar enviar tráfego para esse MAC, o Leaf 2 já sabe diretamente qual VTEP deve utilizar como destino do túnel VXLAN.




EVPN Route Type 2 — MAC/IP Advertisement

EVPN Route Type 2 (MAC/IP Advertisement)	
MAC	AA:AA:AA:AA:AA:01
IP	192.168.10.15
VNI	10010
VTEP	10.0.0.11

- O EVPN define diferentes tipos de rotas para transportar diferentes informações do Overlay.
- A EVPN Route Type 2 — MAC/IP Advertisement Route é utilizada para anunciar informações de alcançabilidade de MAC addresses e, opcionalmente, endereços IP associados.
- Dessa forma, um VTEP pode aprender remotamente tanto a localização Layer 2 de um dispositivo quanto informações relacionadas ao seu endereço Layer 3.
- Para uma introdução ao EVPN, esse é o tipo de rota mais importante, pois demonstra diretamente como o BGP passa a distribuir informações que antes dependiam do aprendizado Ethernet tradicional.

Underlay e Overlay trabalhando juntos



- O Underlay IP fornece a conectividade entre os VTEPs e normalmente utiliza protocolos de roteamento para garantir que os endereços IP dos switches possam alcançar uns aos outros.
- O BGP EVPN Control Plane distribui informações sobre os dispositivos e redes existentes no Overlay.
- O VXLAN Data Plane utiliza essas informações para encapsular os quadros e transportá-los entre os VTEPs através da rede IP.
- Dessa maneira, cada camada possui uma função específica e a topologia lógica deixa de depender diretamente da topologia física.

Visão Geral: BGP + VXLAN + EVPN

- BGP é um protocolo de troca de informações de alcançabilidade que permite políticas de roteamento e pode transportar diferentes tipos de informação através do MP-BGP.
- VXLAN cria uma rede Overlay, permitindo transportar quadros Ethernet através de uma infraestrutura IP e oferecendo milhões de segmentos lógicos através dos VNIs.
- EVPN utiliza MP-BGP como Control Plane para distribuir informações como MAC addresses e IPs entre os VTEPs, reduzindo a dependência de Flood and Learn.
- A combinação Leaf-Spine + IP Underlay + VXLAN + BGP EVPN forma uma das arquiteturas mais utilizadas atualmente para construir Fabrics escaláveis de Data Centers.

